# Bayesovská klasifikace

- Bayesův vztah pro výpočet podmíněné pravděpodobnosti
  - $\sim$  pravděpodobnost, že platí hypotéza  $\emph{\textbf{H}}$ , pokud pozorujeme  $\emph{\textbf{E}}$

$$P(H \mid E) = \frac{P(E \mid H)P(H)}{P(E)}$$

- P(H) ..... apriorní pravděpodobnost hypotézy H
- *P(H|E)* ..... aposteriorní (podmíněná) pravděpodobnost
- P(E) ..... pravděpodobnost pozorování E

# Bayesovská klasifikace (2)

- ightarrow nejpravděpodobnější hypotéza  $H_{MAP}$ 
  - ~ největší aposteriorní pravděpodobnost

$$H_{MAP} = H_J$$
;  $P(H_J \mid E) = \max_t \frac{P(E \mid H_t) P(H_t)}{P(E)}$ 

 $\rightarrow$  zanedbat jmenovatele:  $P(E) = \sum_{t} P(E | H_t) P(H_t)$ 

$$H_{MAP} = H_J \Leftrightarrow P(E \mid H_J) P(H_J) = \max_t (P(E \mid H_t) P(H_t))$$

# Bayesovská klasifikace (3)

#### Příklad:

- Poskytnout úvěr klientovi s vysokým příjmem?
  - P(PUJCIT) = 0.667
  - P(NEPUJCIT) = 0.333
  - $P(VYS\_PRIJEM|PUJCIT) = 0.91$
  - $P(VYS\_PRIJEM|NEPUJCIT) = 0.12$
  - P(NIZ PRIJEM|PUJCIT) = 0.09
  - $P(NIZ\_PRIJEM|NEPUJCIT) = 0.88$
  - $P(VYS\_PRIJEM|PUJCIT) P(PUJCIT) = 0.607$
  - P(VYS PRIJEM|NEPUJCIT) P(NEPUJCIT) = 0.040
  - $\rightarrow H_{MAP} = PUJCIT$

## Naivní Bayesovský klasifikátor

### Předpoklad:

- jednotlivá pozorování  $E_1, ..., E_K$  jsou podmíněně nezávislá při platnosti hypotézy H
- tento předpoklad bývá v reálných úlohách jen málokdy splněn → proto označení "naivní"
- $\rightarrow$  výpočet aposteriorní pravděpodobnosti hypotézy při platnosti všech  $E_1, ..., E_K$

$$P(H | E_1,...,E_K) = \frac{P(E_1,...,E_K | H)P(H)}{P(E_1,...,E_K)}$$

### Naivní Bayesovský klasifikátor (2)

 $\rightarrow$  výpočet aposteriorní pravděpodobnosti hypotézy při platnosti všech  $E_1, ..., E_k$  jako

$$P(H | E_1, ..., E_K) = \frac{P(H)}{P(E_1, ..., E_K)} \prod_{k=1}^K P(E_k | H)$$

 $\rightarrow$  při klasifikaci pomocí naivního Bayesovského klasifikatoru budeme hledat hypotézu s největší aposteriorní pravděpodobností  $H_{MAP}$ 

$$H_{MAP} = H_J \iff P(H_J) \prod_{k=1}^K P(E_k \mid H_J) = \max_t \left( P(H_t) \prod_{k=1}^K P(E_k \mid H_t) \right)$$

### Naivní Bayesovský klasifikátor (3)

- $P(H_t) = P(t\check{r}idy_t) =$   $= Po\check{c}et_vzor\mathring{u}_z_t / Po\check{c}et_v\check{s}ech_vzor\mathring{u}$
- $P(E_k|H_t) = P(vzor\mathring{u}_z_t \check{t}idy_t vyhovujicich_E_k = \frac{Po\check{c}et_vzor\mathring{u}_z_t splňujicich_E_k}{Po\check{c}et_vzor\mathring{u}_z_t t}$

### Naivní Bayesovský klasifikátor (4)

- + možnost klasifikovat i neúplně popsané vzory
- nulová aposteriorní pravděpodobnost  $P(E_k|H_t)$ při chybějících vzorech v trénovací množině (pro  $E_k$ )

evtl. podhodnocení  $P(E_k|H_t)$  při nízké vzájemné četnosti  $E_k$  a  $H_t$ 

## Bayesovská síť - příklady

### Příklad: trénovací data pro Bayesovský klasifikátor

			•	•	
KLIENT	Marise	KONTO	POHLAVI	NEZAMESTNANY	UVER
KI	VYSORY	VYSOKE	ZENA	NE	ANO
k2	VYSOKY	VYSOKE	MUE	NE	ANO
<b>K3</b>	Nizky'	NIZKÉ	MUL	NE	NE
24	NIZEY	VYSOKÉ	ZENA	ANO	ANO
K 5	<i>nieky</i>	VYSOKE'	MUE	ANO	ANO
KG.	NIZKY	NIZKE	ZENA	ANO	NE
4.7	vysoký	NIZKE	MUZ	NE	ANO
KR	VYSOKÝ	NIEKE	ZENA	ANO	ANO
49	NIZEY	STEEDNI	MUE	ANO	NE
£10	vysoky	STREDNÍ	ZENA	NE	AND
K11	NIZKY	STEEDNÍ	ZENA	ANO	NE
K 12	NIZKY	STREDNÍ	MUE	NE	AND

# Bayesovská síť - příklady (2)

### Příklad (pokračování):

Apriorní pravděpodobnost různých hodnot cílového atributu ÚVĚR:

```
P(UVER (ANO)) = 4/12 = 0,667

P(UVER (NE)) = 4/12 = 0,333

P(KONTO (STREDNÍ) I ÚVER (ANO)) = 2/1 = 0,25

P(KONTO (STREDNÍ) I ÚVER (NE)) = 2/4 = 0,5

P(NEZAMESTNANÝ (NE) I ÚVER (ANO)) = 5/1 = 0,625

P(NEZAMESTNANÝ (NE) I ÚVER (NE)) = 1/4 = 0,25
```

# Bayesovská síť - příklady (3)

### Příklad (pokračování):

→ Pro uchazeče o úvěr, který má středně vysoký
 zůstatek na kontě a není nezaměstnaný, spočítáme:

```
P(UVER (ANO)) P(LONTO (STREDNÍ) IUVER (ANO)).

. P(NERAMESTNANÝ (NE) IÚVER (ANO)) = 0, 1042

P(ÚVER (NE)) P(LONTO (STREDNÍ) I ÚVER (NE)).

. P(NERAMESTNANÝ (NE) I ÚVER (NE)) = 0,0416
```

→ Uchazeč bude zařazen do třídy ÚVĚR (ANO)